

Causalidade

Manoel Galdino

2026-08-11

Causalidade, no contexto da estatística, é a demonstração crível de que um fenômeno causa outro na média, sem ser confundido com explicações alternativas. Nas ciências sociais, dela dependem perguntas como: uma reforma eleitoral altera o sistema partidário? Educação reduz desigualdade de renda? Todas esbarram numa dificuldade fundamental: saber se uma causa produziu certo resultado exigiria comparar o mundo observado com outro, idêntico nos aspectos relevantes, sem essa causa. Como apenas um desses mundos é observado, os dados não revelam diretamente efeitos causais.

A inferência causal moderna organiza esse problema por meio da comparação de contrafactuais, tipicamente entre o tratamento e o controle — termos tomados da medicina. Sua contribuição foi explicitar o que uma alegação causal precisa conter: qual é o efeito causal de interesse, sob quais pressupostos ele é estimável sem viés e por que esses pressupostos são críveis no caso estudado. Este verbete focaliza a tradição contrafactual de estimação de efeitos; não pretende esgotar mecanismos, *process tracing*, análise qualitativa comparativa (QCA) ou outras tradições. Reconstrói essa transformação, sua lógica, ganhos, limites e exemplos, e contrasta a difusão internacional da revolução da credibilidade com sua incorporação nos periódicos brasileiros analisados.

Sumário

1. Histórico e fundamentos epistemológicos
2. Lógica de aplicação e decisões de desenho
3. Vantagens, limites e vieses conhecidos
4. Exemplos de aplicação em ciências sociais
5. Debates contemporâneos, escopo e Brasil
6. Referências e leituras adicionais
7. Ver também
8. Como citar este verbete

1. Histórico e fundamentos epistemológicos

Causalidade tem uma longa história, que remonta pelo menos a Aristóteles. Em sua formulação científica contemporânea, porém, o debate sobre tabagismo e câncer de pulmão talvez constitua o episódio histórico mais informativo para compreender a dificuldade de realizar inferência causal fora do contexto experimental, com os assim chamados dados observacionais. Em meados do século XX, estudos conduzidos em diferentes populações encontravam associações fortes e consistentes (Hill 1965), mas não seria aceitável atribuir pessoas aleatoriamente ao consumo prolongado de cigarros. A dificuldade era também conceitual: se uma causa fosse entendida como algo que produzisse invariavelmente o mesmo resultado, fumantes que nunca desenvolveram câncer e não fumantes que o desenvolveram pareceriam contradizer a afirmação causal. A conclusão da saúde pública precisou apoiar-se na convergência de diferentes linhas de evidência, não em um experimento ou teste decisivo. Em 1965, o estatístico Austin Bradford Hill organizou esse julgamento em **nove pontos de vista**: força, consistência, especificidade, temporalidade, gradiente biológico, plausibilidade, coerência, experimento e analogia (Hill 1965). Hill não os apresentou como requisitos cumulativos: advertiu que nenhum fornecia prova indiscutível e nenhum era condição necessária. Eram uma heurística para avaliar explicações rivais, não um algoritmo de identificação. Um gradiente dose-resposta, por exemplo, favorece uma interpretação

simples, mas relações não lineares não deixam por isso de ser causais.

A mudança formal que serve de fio condutor a este verbete começou em outro contexto. Em 1923, Jerzy Neyman representou, em experimentos agrícolas aleatorizados, o rendimento que cada parcela teria sob diferentes condições; a tradução inglesa dessa parte de seu trabalho só seria publicada em 1990 (D. Rubin 2022). A inflexão decisiva ocorreu nos anos 1970. O gênio de Donald Rubin consistiu em colocar a linguagem dos resultados potenciais no centro da definição de efeitos causais e, crucialmente, estender seu uso à análise de dados observacionais (D. B. Rubin 1974). Ao convertê-la de uma ferramenta do experimento em linguagem geral para definir efeitos e explicitar o problema da atribuição, Rubin ajudou a destravar uma agenda de pesquisa que formalizaria a inferência causal observacional. Essa linguagem teria permitido formular com maior precisão a controvérsia sobre tabagismo e câncer: que alguns fumantes jamais desenvolvessem a doença não invalidaria que fumar elevasse causalmente o risco na população. É plausível, portanto, que sua disponibilidade tivesse acelerado a convergência científica, embora não substituísse a evidência acumulada nem resolvesse por si só os problemas de identificação.

Aplicada ao tabagismo, essa linguagem dissolve a aparente contradição. Cada pessoa tem dois desfechos possíveis: o que teria se fumasse no período relevante e o que teria se não fumasse. Apenas um deles chega a ocorrer, e é o único que os dados registram; o outro permanece contrafactual. O efeito do tabagismo sobre aquela pessoa é a diferença entre os dois, e pode ser nulo para algumas e grande para outras. Dizer que o tabagismo causa câncer não exige, portanto, que todo fumante desenvolva a doença: exige que a proporção que desenvolveria câncer fumando seja maior do que a que desenvolveria não fumando. Separar o que de fato aconteceu do que teria acontecido sob a outra alternativa é a chave conceitual que permite definir efeitos causais com precisão e sustenta a agenda quantitativa de inferência causal.

Em paralelo, desenvolveu-se a tradição dos modelos causais estruturais e dos grafos acíclicos direcionados (DAGs, na sigla em inglês), com antecedentes nos diagramas de trajetórias de Sewall Wright e formalização moderna associada a Judea Pearl (Pearl 2009). Resultados potenciais e DAGs diferem em ênfases e notação, mas são complementares: a primeira linguagem define diretamente efeitos e estimandos; a segunda torna visíveis estruturas de dependência e consequências do condicionamento. Por limitação de espaço, este verbete usa resultados potenciais como eixo. A virada decisiva, compartilhada pelas duas tradições, foi explicitar o que uma análise causal deve declarar: a comparação contrafactual e as suposições que conectam os dados observados a ela.

2. Lógica de aplicação e decisões de desenho

Uma pesquisa causal começa antes da escolha de uma técnica. Perguntar se uma política “funciona”, por exemplo, é insuficiente até que sejam definidos a população relevante, as versões da intervenção, o resultado, o horizonte temporal e a comparação contrafactual. Uma reforma eleitoral pode afetar comparecimento, composição do eleitorado ou representação partidária; cada resultado corresponde a uma pergunta diferente. Do mesmo modo, “receber a política” pode significar elegibilidade, oferta, adesão ou exposição efetiva. Essas escolhas definem o objeto causal e não podem ser delegadas ao modelo estatístico.

Na notação de resultados potenciais, $Y_i(1)$ representa o resultado que a unidade i apresentaria sob tratamento e $Y_i(0)$, sob controle. O efeito individual é a diferença $Y_i(1) - Y_i(0)$, mas apenas um dos termos pode vir a ser observado. Sob a condição de consistência, se $X_i = x$, então $Y_i = Y_i(x)$: o resultado potencial correspondente ao tratamento efetivamente recebido é igual ao resultado observado. Essa relação não elimina a distinção conceitual. $Y_i(1)$ designa o resultado que a unidade teria sob tratamento, tenha sido ela tratada ou não; $Y_i \mid X_i = 1$ denota a distribuição do resultado observado entre as unidades que efetivamente receberam o tratamento. Portanto, em geral, $E(Y_i(1))$ ¹ não é igual a $E(Y_i \mid X_i = 1)$; essa igualdade exige suposições de comparabilidade. A notação torna visível precisamente a diferença entre uma quantidade causal e uma associação observada.

Esse arcabouço tornou central um conceito que traz clareza analítica à pesquisa causal: o **estimando**. Um estimando é a quantidade-alvo da análise — o efeito que se pretende conhecer para uma população ou subpopulação — definida independentemente do modelo ou procedimento utilizado para calculá-la (Lundberg, Johnson, e Stewart 2021). Toda pesquisa causal precisa dizer qual efeito pretende estimar e para

¹A notação $E(\cdot)$ denota a esperança matemática, isto é, a média da quantidade entre as unidades da população.

quem. Essa decisão precede a escolha da técnica: o desenho deve ser capaz de identificar a quantidade-alvo, e o estimador deve ser apropriado para estimá-la. O **estimador** é a regra aplicada à amostra; a **estimativa** é o valor numérico efetivamente calculado. A inferência estatística usa essa estimativa para aprender sobre o estimando. Retomando o tabagismo: se a quantidade-alvo é o efeito do cigarro entre os que fumam, esse é um estimando. Se é o efeito sobre toda a população, incluindo os que não fumam, caso passassem a fumar, a quantidade é outra. Os dois só coincidiriam se o cigarro fizesse o mesmo estrago em todo mundo ou se os fumantes fossem um recorte aleatório da população. Como nenhuma das duas coisas vale, são estimandos distintos, com estimadores possivelmente diferentes e estimativas desiguais. A diferença persiste ainda que ambos sejam estimados sem viés.

Variáveis instrumentais mostram por que essa distinção importa. Sob as suposições usuais, o estimando que elas permitem identificar é frequentemente o efeito causal médio local (*Local Average Treatment Effect*, LATE): o efeito apenas entre os *compliers*, unidades cuja exposição ao tratamento muda na direção induzida pelo instrumento (Imbens 2010). Imagine um programa público de capacitação com vagas distribuídas por sorteio, mas adesão imperfeita: alguns sorteados não participam e alguns não sorteados conseguem acesso por outra via. Usar o resultado do sorteio como instrumento para a participação identifica o efeito entre as pessoas que participariam se sorteadas e não participariam se não sorteadas. A condição de monotonicidade exclui os “do contra”: ninguém deve deixar de participar por ter sido sorteado quando participaria sem o sorteio. O LATE não informa necessariamente o efeito entre todos os elegíveis nem o efeito de uma expansão universal do programa. Para decisões de política pública, saber a quem o efeito se refere é tão importante quanto conhecer sua magnitude.

Definir o estimando não garante que ele possa ser aprendido. **Identificação** é a demonstração de que, sob determinadas suposições, a quantidade causal pode ser expressa em termos da distribuição dos dados observados. Em outras palavras, um efeito identificado pode ser aprendido dos dados, enquanto um efeito não identificado não é recuperável nem com amostra infinita; tipicamente o estimador é enviesado. Em um experimento ideal, a atribuição aleatória faz com que grupos tratados e de controle sejam comparáveis em média. Em estudos observacionais, a comparabilidade precisa ser defendida de outras formas. Ausência de confundimento após condicionamento, tendências paralelas, continuidade em torno de um limiar e restrições de exclusão são suposições associadas a desenhos diferentes. Elas não são propriedades automáticas de regressões, pareamento, diferença-em-diferenças, regressão descontínua (RDD) ou variáveis instrumentais; são afirmações sobre o processo que gerou os dados e sobre o mundo social estudado.

Essa distinção também separa identificação de inferência estatística. A primeira pergunta se o desenho, junto às suposições, permite interpretar uma comparação observada como efeito causal. A segunda quantifica quanto a estimativa variaria diante da incerteza amostral ou de outras fontes explicitamente modeladas. Erros-padrão pequenos não corrigem confundimento; intervalos de confiança estreitos podem cercar uma quantidade enviesada. Inversamente, um desenho com argumento de identificação plausível pode produzir estimativas imprecisas. Credibilidade causal e precisão estatística são dimensões distintas e conjuntamente relevantes.

O desenho de pesquisa organiza a ponte entre estimando e dados. Seu papel é explicar de onde vem a variação usada para aproximar o contrafactual. Em experimentos, ela decorre da atribuição conduzida pela pesquisadora. Em experimentos naturais e quase experimentos, regras institucionais, mudanças temporais ou limiares podem gerar comparações informativas. Em outros estudos observacionais, a identificação depende de medir e ajustar adequadamente as causas comuns do tratamento e do resultado. A “revolução da credibilidade” valorizou essa atenção ao desenho porque especificações cada vez mais complexas não solucionavam a fragilidade das comparações subjacentes (Angrist e Pischke 2010). O avanço não aboliu modelos; reposicionou-os dentro de um argumento que começa pela origem da variação.

Essa arquitetura também torna claro um limite da regressão múltipla tradicional. Em uma leitura associacional, é tentador tratar cada coeficiente como o efeito da respectiva variável e converter uma única equação em resposta à pergunta ampla sobre “as causas de Y ”. Mas a interpretação causal não é propriedade automática do coeficiente: para cada variável seria necessário definir o estimando e justificar, separadamente, por que os controles e a origem da variação identificam aquele efeito. Um mesmo ajuste raramente sustenta interpretações causais críveis de todos os coeficientes. Por isso, abordagens contemporâneas de inferência causal frequentemente concentram a análise no efeito de uma exposição específica — ou de um pequeno conjunto — por vez. As demais variáveis entram, em regra, como auxiliares à identificação ou à precisão

desse estimando, não como efeitos adicionais prontos para interpretação. Hünermund e Louw recomendam omitir das tabelas os coeficientes dos controles ou marcá-los explicitamente como não causais, evitando induzir o leitor a interpretá-los como efeitos; a seleção dos controles, entretanto, ainda precisa ser justificada no texto (Hünermund e Louw 2025).

DAGs ajudam a tornar esse argumento auditável. Se uma variável causa tanto o tratamento quanto o resultado, ela abre um caminho de confundimento que pode exigir bloqueio. Se, ao contrário, a variável é consequência comum de duas outras — um colisor —, condicioná-la pode criar associação onde antes não havia. Variáveis medidas após o tratamento podem representar mecanismos, efeitos intermediários ou novos colisores, e seu controle altera a pergunta respondida. Na linguagem dos modelos causais estruturais, intervir em X não equivale a apenas observar unidades com $X = x$. O grafo, porém, só é tão defensável quanto as relações causais nele postuladas.

Resultados potenciais tornam especialmente clara a necessidade de estabilidade da intervenção e de ausência de interferência: o resultado de uma unidade deve ser definido em relação a um tratamento suficientemente preciso, e não depender inadvertidamente do tratamento recebido por outras unidades. Já a representação gráfica facilita localizar caminhos pelos quais essas condições podem falhar. A escolha entre linguagens deve ser guiada pelo problema, não por lealdade de escola. Em ambas, o ganho consiste em reduzir ambiguidades e expor onde o argumento depende de conhecimento externo aos dados.

Uma sequência lógica emerge. Primeiro vem a pergunta causal; depois, o estimando que a traduz. Em seguida, explicita-se a estrutura causal relevante, escolhe-se um desenho e declaram-se as suposições de identificação. Só então se selecionam estimador e procedimento de inferência compatíveis. Essa ordem não é uma receita mecânica: teoria e evidência podem levar à revisão de etapas anteriores. Ela funciona como disciplina argumentativa. Ao obrigar a pesquisadora a dizer o que pretende aprender e por que a comparação é informativa, impede que a interpretação causal seja acrescentada apenas depois que um coeficiente estatisticamente significativo apareceu. Como enfatizam Lundberg, Johnson e Stewart, estimandos claros conectam teoria, evidência e análise, mas não substituem a defesa da identificação (Lundberg, Johnson, e Stewart 2021).

3. Vantagens, limites e vieses conhecidos

A principal vantagem da formalização causal é a auditabilidade. Quando estimando, desenho e suposições são declarados, discordâncias deixam de se concentrar apenas na escolha de uma especificação e podem alcançar o argumento substantivo. Torna-se possível perguntar se o tratamento corresponde ao conceito teórico, se o grupo de comparação representa o contrafactual e se o efeito identificado responde à questão que motivou a pesquisa. A linguagem também revela erros que uma análise puramente associacional pode ocultar.

O **confundimento** ocorre quando causas do tratamento também influenciam o resultado. Municípios que adotam voluntariamente uma política, por exemplo, podem diferir de outros antes da adoção. Compará-los sem representar adequadamente esse processo mistura o efeito da política com diferenças prévias. A seleção produz problema semelhante quando a entrada na amostra, a permanência no estudo ou a observação do resultado depende de tratamento e resultado. Controlar muitas covariáveis não assegura solução: algumas causas comuns podem não ter sido medidas, e a flexibilidade do ajuste pode apenas tornar menos transparente a dependência de suposições.

O controle também pode introduzir viés. Quando o estimando é o efeito total, variáveis afetadas pelo tratamento são, em geral, controles inadequados. Se a variável é um **mediador**, controlá-la bloqueia parte do caminho pelo qual o tratamento produz o resultado. Se é um **colisor pós-tratamento** — efeito comum do tratamento e de outra causa do resultado —, condicioná-la pode abrir um caminho não causal entre tratamento e resultado. Mediadores e colisores pós-tratamento são, portanto, *bad controls* para o efeito total, embora por razões distintas. Nem todo colisor, contudo, é pós-tratamento. A pergunta “por quais mecanismos?” é legítima, mas corresponde a outro estimando; analisar efeitos diretos exige métodos e suposições adicionais. DAGs são úteis porque distinguem visualmente confundidores, mediadores e colisores que uma lista indiferenciada de controles trataria como equivalentes.

Interferência e contaminação desafiam a ideia de unidades isoladas. Campanhas, epidemias, redes

sociais e políticas territoriais frequentemente produzem transbordamentos: o tratamento de uma unidade modifica o resultado de outra. Nesses casos, $Y_i(1)$ e $Y_i(0)$ são descrições incompletas, pois o resultado depende também da exposição alheia. A solução nem sempre é eliminar a interferência; frequentemente é redefinir tratamentos e estimandos para representar os padrões de exposição relevantes. Ignorá-la pode atenuar comparações ou fazê-las responder a uma combinação indeterminada de efeitos diretos e indiretos.

Erro de mensuração também pode mudar a pergunta causal. Indicadores administrativos podem registrar acesso ao programa, não tratamento efetivo; escalas de atitudes podem responder à própria intervenção; classificações territoriais podem ser alteradas pela política. O erro não se limita necessariamente a aumentar a incerteza: se for diferencial ou atingir tratamento, resultado e seleção de maneira relacionada, pode deslocar sistematicamente a estimativa. A validade de construto, portanto, integra a identificação e não é uma etapa meramente preliminar de limpeza de dados.

Mesmo desenhos internamente convincentes enfrentam limites de alcance. Um efeito médio pode esconder heterogeneidade; um RDD identifica tipicamente um efeito próximo do limiar; uma variável instrumental pode identificar um efeito para as unidades cujo tratamento é alterado pelo instrumento. Transportar esses efeitos para outras populações, épocas ou versões da intervenção requer informações e suposições adicionais. Validade externa não é uma propriedade que a aleatorização ou a significância estatística concedem automaticamente. Ela depende de como mecanismos, contextos e composição da população se modificam.

Há ainda limites de escopo. A linguagem de tratamentos é poderosa para perguntar o que ocorreria sob intervenções ou exposições alternativas, mas nem toda explicação social assume naturalmente essa forma. Relações constitutivas, significados, processos históricos e mecanismos complexos podem exigir outras unidades de análise. A resposta é delimitar o que o estimando representa.

Por fim, nomear um desenho não comprova suas condições. Tendências anteriores semelhantes apoiam, mas não demonstram, tendências paralelas futuras; continuidade de covariáveis não prova ausência de manipulação em um limiar; placebos informam sobre falhas específicas, não certificam todo o argumento. A credibilidade resulta da convergência entre conhecimento substantivo, regras institucionais, diagnósticos e análises de sensibilidade. A formalização causal melhora a crítica precisamente porque permite localizar o ponto em que cada inferência pode falhar.

4. Exemplos de aplicação em ciências sociais

Dois estudos observacionais mostram como o desenho organiza a interpretação causal. Card e Krueger investigaram o efeito do aumento do salário mínimo de Nova Jersey sobre o emprego em restaurantes de *fast-food* (Card e Krueger 1994). Comparar apenas o emprego estadual antes e depois da mudança confundiria o efeito da política com choques temporais. Comparar apenas Nova Jersey e Pensilvânia depois da reforma confundiria a política com diferenças permanentes entre os estados. A diferença-em-diferenças combina os dois contrastes: pergunta quanto a mudança do emprego em Nova Jersey se afastou da mudança observada no estado vizinho, onde o salário mínimo não aumentou.

O estimando substantivo é o efeito da elevação do piso salarial sobre o emprego nos estabelecimentos estudados. Sua identificação requer que, sem a reforma, a evolução de Nova Jersey fosse adequadamente representada pela Pensilvânia. Essa condição de tendências paralelas é contrafactual e não se torna verdadeira por aplicação da fórmula. Proximidade geográfica e comportamento anterior podem torná-la plausível, enquanto choques estaduais simultâneos, transbordamentos ou mensuração desigual do emprego podem enfraquecê-la. Nos resultados principais reportados, os autores não encontraram a redução do emprego prevista pelo modelo competitivo simples. A inferência, por sua vez, precisa refletir a estrutura do desenho e a dependência entre as observações usadas no contraste. O estudo tornou-se paradigmático por deslocar o debate sobre salário mínimo para a qualidade da comparação.

Em uma aplicação brasileira, Avelino, Biderman e Barone perguntam se eleger um prefeito aumenta posteriormente a votação de seu partido no município (Avelino, Biderman, e Barone 2012). Os autores conectam as eleições municipais de 2008 às votações para deputado federal e estadual em 2010 e exploram a descontinuidade produzida por vitórias apertadas. Partidos vencedores e derrotados por margens muito pequenas tendem a ser semelhantes em força eleitoral, mas apenas os vencedores passam a controlar a prefeitura. Assim, a posição imediatamente acima ou abaixo do limiar fornece uma comparação quase

experimental para estimar o efeito de eleger o prefeito.

A janela de disputas decididas por menos de um ponto percentual reúne 266 municípios. Usando essa amostra, o artigo reporta uma diferença estimada de 3,7 pontos percentuais na votação subsequente para deputado federal; com controle pela votação para vereador, a estimativa é de 3,4 pontos. O contraste é observacional, embora a identificação explore variação aproximadamente aleatória perto do limiar. A lógica de identificação do RDD e seu alcance devem ser formulados localmente: partidos em disputas muito apertadas não representam automaticamente todos os municípios. A inferência também deve acompanhar a estimação e a janela escolhida em torno do limiar. Além disso, a especificação principal emprega um polinômio de quarto grau, escolha que exige cautela, justificativa e diagnósticos antes de certificar a interpretação. O caso é, por isso, duplamente instrutivo: mostra a força de uma regra institucional para construir o contrafactual e recorda que a presença de um desenho reconhecido não certifica sua execução ou interpretação.

5. Debates contemporâneos, escopo e Brasil

A revolução da credibilidade deslocou o padrão de justificação empírica. Em vez de confiar principalmente no ajuste de modelos e na inclusão de controles, parte da economia e, depois, da Ciência Política passou a valorizar experimentos, experimentos naturais e desenhos quase experimentais cuja fonte de variação pudesse ser explicada. Angrist e Pischke interpretaram essa mudança como resposta à baixa credibilidade da econometria aplicada (Angrist e Pischke 2010). Seu legado é a expectativa de que a credibilidade do desenho de pesquisa seja defendida antes da estimação.

Uma crítica recorrente alerta para uma redução da ambição substantiva: diante dos incentivos de publicação, pesquisadores podem escolher estrategicamente perguntas menores com variação exógena evidente e transformar a robustez do desenho no principal critério de qualidade. O risco é real. Imbens o reconhece em *Better LATE Than Nothing*, mas defende que validade interna e delimitação da população elevaram a credibilidade da pesquisa: em sua formulação, um efeito local crível é preferível a um efeito geral pouco crível (Imbens 2010). Esse estreitamento não é defeito necessário da revolução; é resposta evitável da comunidade científica à elevação da barra. Periódicos, pareceristas e pesquisadores podem exigir simultaneamente relevância substantiva e respostas críveis. Tampouco está demonstrado que a agenda tenha se tornado menos relevante ou ambiciosa; demonstrá-lo exigiria medir relevância e ambição antes e depois da mudança metodológica, o que o debate citado não faz. Elevar a barra é desejável. O desafio é não reduzir a pergunta para alcançá-la, mas mobilizar criatividade para encontrar variações informativas, combinar desenhos e construir novas bases de dados.

Torreblanca e colaboradores permitem dimensionar a difusão dessa expectativa na Ciência Política internacional (Torreblanca et al. 2026). O estudo classifica 91.632 artigos publicados entre 2003 e 2023 em 156 periódicos. Os autores encontram crescimento de pesquisas baseadas em desenho e associação positiva com citações. A transformação, contudo, é parcial e desigual: concentra-se em periódicos de maior prestígio e em instituições mais bem posicionadas nas classificações, é impulsionada sobretudo por experimentos de levantamento e convive com o uso ainda raro de testes de placebo e cálculos de poder estatístico. Neste verbete, “fronteira internacional” designa os segmentos editoriais e institucionais influentes cobertos pelo estudo, não a disciplina inteira. Os resultados documentam difusão desigual da atenção a estimandos, desenhos e identificação.

O contraste brasileiro precisa respeitar universos e denominadores distintos. Galdino e Martins da Silva analisam o texto integral de 4.144 artigos elegíveis publicados entre 2005 e 2025 em nove periódicos brasileiros indexados no SciELO (Galdino e Martins da Silva 2026). Entre 1.994 artigos quantitativos com inferência classificada, 743, ou 37,3%, quantificam formalmente a incerteza. Em todo o corpus, apenas 59 artigos, ou 1,4%, mencionam uma estratégia explícita de identificação causal. Em uma categoria distinta, 1.885 artigos, equivalentes a 45,5% do corpus, combinam linguagem causal ou explicativa e análise quantitativa sem mencionar estratégia explícita de identificação.

Essas medidas descrevem práticas textualmente registradas, não a qualidade de sua execução. A presença de termos como RDD ou diferença-em-diferenças não demonstra que os pressupostos foram satisfeitos; sua ausência também não prova que toda interpretação substantiva seja inadequada. Além disso, a categoria “causal ou explicativa” reúne ambições de alcance diferente. Os resultados sinalizam um possível desalinhamento entre a difusão de linguagem explicativa e a explicitação do desenho, mas não constituem

uma auditoria individual de cada alegação. As classificações automatizadas ainda requerem validação humana.

Também seria incorreto comparar diretamente o 1,4% brasileiro com as proporções internacionais. Torreblanca e colaboradores avaliam, entre outros recortes, artigos quantitativos explicativos de periódicos internacionais e classificam abordagens baseadas em desenho; Galdino e Martins da Silva partem de todos os artigos elegíveis dos nove periódicos e medem menção explícita a estratégias causais. Período, seleção de revistas, unidade de análise e regras de classificação diferem. A leitura conjunta pode ser apenas substantiva: nos periódicos brasileiros analisados, a quantificação da incerteza ainda não é prática majoritária entre os quantitativos; os achados internacionais são compatíveis com atenção crescente à qualidade da identificação nos segmentos editoriais e institucionais influentes cobertos por Torreblanca e colaboradores. Esse deslocamento é uma interpretação compatível com o conjunto de indicadores, não um resultado diretamente medido. As frequências brasileiras sustentam apenas uma incorporação ainda incompleta no corpus; avaliar se essa incorporação também foi tardia exige evidência temporal comparável.

A centralidade contemporânea dos desenhos não deve estreitar indevidamente o conceito de causalidade. *Process tracing*, análise histórico-comparativa, QCA e outras abordagens configuracionais também formulam perguntas causais, frequentemente concentradas em mecanismos, sequências, condições necessárias ou combinações suficientes. Um verbete precisa escolher o que desenvolver. Aqui, essas tradições são delimitadas pelo espaço disponível e pela necessidade de apresentar outras unidades de evidência e lógicas inferenciais; não são excluídas por irrelevância.

Essa delimitação preserva uma distinção importante. Causas podem ser tratadas como intervenções, mas também como condições dentro de configurações, processos que conectam eventos ou estruturas que constituem atores e possibilidades. Explicar o efeito de uma mudança não é o mesmo que reconstruir seu mecanismo, interpretar seu significado ou mostrar como uma categoria social foi constituída. A clareza causal exige reconhecer tanto o que o desenho identifica quanto o que permanece fora dele.

A virada moderna, portanto, não encerrou a pluralidade das explicações sociais. Ela elevou o padrão mínimo para uma classe importante de alegações: quando uma pesquisa afirma que mudar X alteraria Y , precisa definir a quantidade causal, justificar a comparação que representa o contrafactual e separar identificação de incerteza estatística. Métodos podem mudar e diagnósticos podem se tornar mais exigentes. A exigência permanece: dizer qual efeito está em jogo e por que os dados permitem aprendê-lo.

6. Referências e leituras adicionais

Textos fundadores: Hill organiza o julgamento causal observacional; Rubin coloca os resultados potenciais no centro de estudos experimentais e observacionais e reconstrói em entrevista a genealogia que remonta a Neyman; Pearl dá aos grafos causais sua formalização moderna (Hill 1965; D. B. Rubin 1974; D. Rubin 2022; Pearl 2009).

Desenho e estimandos: Angrist e Pischke sintetizam a revolução da credibilidade; Imbens defende o ganho de validade interna; Lundberg, Johnson e Stewart mostram a função teórica do estimando (Angrist e Pischke 2010; Imbens 2010; Lundberg, Johnson, e Stewart 2021).

Aplicações observacionais: Card e Krueger exemplificam diferença-em-diferenças; Avelino, Biderman e Barone aplicam RDD a eleições brasileiras (Card e Krueger 1994; Avelino, Biderman, e Barone 2012).

Controles, fronteira e Brasil: Hünermund e Louw discutem a interpretação dos coeficientes de controle; Torreblanca e colaboradores documentam a difusão internacional; Galdino e Martins da Silva analisam os periódicos brasileiros (Hünermund e Louw 2025; Torreblanca et al. 2026; Galdino e Martins da Silva 2026).

Angrist, Joshua D., e Jörn-Steffen Pischke. 2010. “The Credibility Revolution in Empirical Economics: How Better Research Design Is Taking the Con out of Econometrics”. *Journal of Economic Perspectives* 24 (2): 3–30.

Avelino, George, Ciro Biderman, e Leonardo S. Barone. 2012. “Articulações Intrapartidárias e Desempenho Eleitoral no Brasil”. *Dados* 55 (4): 987–1013. <https://doi.org/10.1590/S0011-52582012000400005>.

Card, David, e Alan B. Krueger. 1994. “Minimum Wages and Employment: A Case Study of the Fast-Food

- Industry in New Jersey and Pennsylvania”. *American Economic Review* 84 (4): 772–93.
- Galdino, Manoel, e Rodrigo Martins da Silva. 2026. “Depois do calcanhar metodológico: inferência e identificação causal na Ciência Política brasileira”. Em *Paper apresentado no 15º Encontro da Associação Brasileira de Ciência Política, 4 de agosto de 2026*.
- Hill, Austin Bradford. 1965. “The Environment and Disease: Association or Causation?” *Proceedings of the Royal Society of Medicine* 58 (5): 295–300.
- Hünernmund, Paul, e Beyers Louw. 2025. “On the Nuisance of Control Variables in Causal Regression Analysis”. *Organizational Research Methods* 28 (1): 138–51. <https://doi.org/10.1177/10944281231219274>.
- Imbens, Guido W. 2010. “Better LATE Than Nothing: Some Comments on Deaton (2009) and Heckman and Urzua (2009)”. *Journal of Economic Literature* 48 (2): 399–423. <https://doi.org/10.1257/jel.48.2.399>.
- Lundberg, Ian, Rebecca Johnson, e Brandon M. Stewart. 2021. “What Is Your Estimand? Defining the Target Quantity Connects Statistical Evidence to Theory”. *American Sociological Review* 86 (3): 532–65. <https://doi.org/10.1177/00031224211004187>.
- Pearl, Judea. 2009. *Causality: Models, Reasoning, and Inference*. 2º ed. Cambridge: Cambridge University Press.
- Rubin, Don. 2022. “Interview with Don Rubin”. *Observational Studies* 8 (2): 77–94. <https://doi.org/10.1353/obs.2022.0009>.
- Rubin, Donald B. 1974. “Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies”. *Journal of Educational Psychology* 66 (5): 688–701.
- Torreblanca, Carolina, William Dinneen, Guy Grossman, e Yiqing Xu. 2026. “The Credibility Revolution in Political Science”. <https://doi.org/10.48550/arXiv.2601.11542>.

7. Ver também

- Desenho de pesquisa;
- Explicação;
- Mecanismos causais;
- Experimentos;
- *Process tracing*;
- Correlação;
- Validade interna e externa.

8. Como citar este verbete