

Causalidade

Manoel Galdino

2026-08-17

Causalidade, no contexto da estatística, é a demonstração crível de que um fenômeno causa outro em média, sem ser confundido com explicações alternativas. Nas ciências sociais, dela dependem perguntas como: uma reforma eleitoral altera o sistema partidário? Educação reduz desigualdade de renda? Todas esbarram numa dificuldade fundamental: saber se uma causa produziu certo resultado exigiria comparar o mundo observado com outro, idêntico nos aspectos relevantes, sem essa causa. Como apenas um desses mundos é observado, os dados não revelam diretamente efeitos causais.

A inferência causal moderna organiza esse problema por meio da comparação de contrafactuais, tipicamente entre o tratamento e o controle — termos tomados da medicina. Sua contribuição foi explicitar o que uma alegação causal precisa conter: qual é o efeito causal de interesse, sob quais pressupostos ele é estimável sem viés e por que esses pressupostos são críveis no caso estudado. Este verbete focaliza a tradição contrafactual de estimação de efeitos; não pretende esgotar mecanismos, *process tracing*, análise qualitativa comparativa (QCA) ou outras tradições. Reconstrói essa transformação, sua lógica, ganhos, limites e exemplos, e contrasta a difusão internacional da revolução da credibilidade com sua incorporação nos periódicos brasileiros analisados.

Sumário

1. Histórico e fundamentos epistemológicos
2. Lógica de aplicação e decisões de desenho
3. Vantagens, limites e vieses conhecidos
4. Exemplos de aplicação em ciências sociais
5. Debates contemporâneos, escopo e Brasil
6. Referências e leituras adicionais
7. Ver também
8. Como citar este verbete

1. Histórico e fundamentos epistemológicos

Causalidade tem uma longa história, que remonta pelo menos a Aristóteles e seus quatro tipos de causas. Em sua formulação científica contemporânea, porém, o debate sobre tabagismo e câncer de pulmão talvez constitua o episódio histórico mais informativo para compreender a dificuldade de realizar inferência causal fora do contexto experimental. Em meados do século XX, havia bastante evidência da correlação entre tabagismo e câncer de pulmão (Hill 1965) e muito debate sobre como inferir causalidade. A dificuldade era também conceitual: se uma causa fosse entendida como algo que produzisse invariavelmente o mesmo resultado, fumantes que nunca desenvolveram câncer e não fumantes que o desenvolveram pareceriam contradizer a afirmação causal. A conclusão da saúde pública precisou apoiar-se na convergência de diferentes linhas de evidência, em vez de um experimento ou teste decisivo. Em 1965, o estatístico Austin Bradford Hill organizou esse julgamento em nove critérios: força, consistência, especificidade, temporalidade, gradiente biológico, plausibilidade, coerência, experimento e analogia (Hill 1965). Contudo, a lista era *ad hoc* e não resolvia o problema fundamental de definir causalidade e identificar inequivocamente quando podíamos falar de causalidade. Fora do contexto experimental, não havia uma lógica clara para realizar inferência causal.

A linguagem que seria usada posteriormente já existia. Em trabalho de 1923 (cuja tradução em

inglês apareceria apenas em 1990), Jerzy Neyman representou formalmente, em experimentos agrícolas aleatorizados, o rendimento que cada parcela teria sob diferentes condições, ou seja, os rendimentos potenciais (D. Rubin 2022). O gênio do estatístico Donald Rubin consistiu em colocar essa linguagem dos resultados potenciais no centro da definição de efeitos causais e, crucialmente, estender seu uso à análise de dados observacionais (D. B. Rubin 1974). Ao convertê-la de uma ferramenta do experimento em linguagem geral para definir efeitos e explicitar o problema da atribuição, Rubin ajudou a destravar uma agenda de pesquisa que formalizaria a inferência causal observacional. Essa linguagem teria permitido formular com maior precisão a controvérsia sobre tabagismo e câncer: que alguns fumantes jamais desenvolvessem a doença não invalidaria que fumar elevasse causalmente o risco médio na população, por exemplo.

O arcabouço funciona do seguinte modo: cada pessoa tem dois desfechos possíveis, o que teria se fumasse no período relevante e o que teria se não fumasse. Apenas um deles chega a ocorrer, e é o único que os dados registram; o outro permanece contrafactual. O efeito do tabagismo sobre aquela pessoa é a diferença entre os dois resultados potenciais, e pode ser nulo para algumas e grande para outras. Assim, quando falamos em causalidade, tipicamente estamos falando da média de uma população, pois os efeitos individuais podem variar. Dizer que o tabagismo causa câncer não exige, portanto, que todo fumante desenvolva a doença: exige que a proporção que desenvolveria câncer fumando seja maior do que a que desenvolveria não fumando. Separar o que de fato aconteceu do que teria acontecido sob a outra alternativa é a chave conceitual que permite definir efeitos causais com precisão e sustenta a agenda quantitativa de inferência causal.

Em paralelo, desenvolveu-se a tradição dos modelos causais estruturais e dos grafos acíclicos direcionados (DAGs, na sigla em inglês), com antecedentes nos diagramas de trajetórias de Sewall Wright e formalização moderna associada a Judea Pearl (Pearl 2009). Resultados potenciais e DAGs diferem em ênfases e notação, mas matematicamente são equivalentes. O que é verdadeiro em uma linguagem também o é na outra. A virada decisiva, compartilhada pelas duas tradições, foi explicitar o que uma análise causal deve declarar: a comparação contrafactual e as suposições que conectam os dados observados a ela. Por limitação de espaço, este verbete usa resultados potenciais, paradigma *mainstream* na ciência política, como eixo, mas ambas as abordagens são úteis e relevantes para a moderna inferência causal.

2. Lógica de aplicação e decisões de desenho

Uma pesquisa causal começa antes da escolha de uma técnica. Perguntar se uma política “funciona”, por exemplo, é insuficiente até que sejam definidos a população relevante, as versões da intervenção, o resultado, o horizonte temporal e a comparação contrafactual. Se queremos estudar o efeito de uma reforma eleitoral qualquer sobre o comparecimento, a questão-chave é qual o contrafactual de comparação: o sistema eleitoral anterior? O sistema eleitoral de outra região? Essas escolhas definem o objeto causal e não podem ser delegadas ao modelo estatístico.

Na notação de resultados potenciais, $Y_i(1)$ representa o resultado que a unidade i apresentaria sob tratamento e $Y_i(0)$, sob controle. Note que o resultado, ou a variável dependente, é tipicamente representado por Y e indexado em i para a unidade i ; ele tem um componente adicional, representado por (1) ou (0). Os números entre parênteses indicam o mundo imaginário ou potencial em que a única diferença relevante é que a unidade recebeu o tratamento – (1) – ou o controle – (0).

O efeito individual é a diferença $Y_i(1) - Y_i(0)$, mas apenas um dos termos pode vir a ser observado. Ou seja, se $X_i = x$, então $Y_i = Y_i(x)$: o resultado potencial correspondente ao tratamento efetivamente recebido é igual ao resultado observado. Essa relação não elimina a distinção conceitual. $Y_i(1)$ designa o resultado que a unidade teria sob tratamento, tenha sido ela tratada ou não; $Y_i \mid X_i = 1$ denota a distribuição do resultado observado entre as unidades que efetivamente receberam o tratamento. Portanto, em geral, $E(Y_i(1))$ ¹ não é igual a $E(Y_i \mid X_i = 1)$. No primeiro caso, estamos falando de resultados potenciais. No segundo, de resultados efetivamente observados. Pode ser que as duas quantidades coincidam, mas não necessariamente. A notação torna visível precisamente a diferença entre uma quantidade causal e uma associação observada.

Esse arcabouço tornou central um conceito que traz clareza analítica à pesquisa causal: o estimando. Um estimando é a quantidade-alvo da análise — o efeito que se pretende conhecer para uma população ou

¹A notação $E(\cdot)$ denota a esperança matemática, isto é, a média da quantidade entre as unidades da população.

subpopulação — definida independentemente do modelo ou procedimento utilizado para calculá-la (Lundberg, Johnson, e Stewart 2021). Toda pesquisa causal precisa dizer qual efeito pretende estimar e para quem. Essa decisão precede a escolha da técnica: o desenho deve ser capaz de identificar a quantidade-alvo, e o estimador deve ser apropriado para estimá-la. O estimador é a regra aplicada à amostra; a estimativa é o valor numérico efetivamente calculado. A inferência estatística usa essa estimativa para aprender sobre o estimando. Retomando o exemplo do tabagismo: se a quantidade-alvo é o efeito do cigarro entre os que fumam, esse é um estimando. Se é o efeito sobre toda a população, incluindo os que não fumam, caso passassem a fumar, a quantidade é outra. Os dois só coincidiriam se o cigarro fizesse o mesmo estrago em todo mundo ou se os fumantes fossem um recorte aleatório da população. Como nenhuma das duas coisas vale, são estimandos distintos, com estimadores possivelmente diferentes e estimativas desiguais. A diferença persiste ainda que ambos sejam estimados sem viés.

Variáveis instrumentais mostram por que essa distinção importa. Sob as suposições usuais, o estimando que elas permitem identificar é frequentemente o efeito causal médio local (*Local Average Treatment Effect*, LATE), ou seja, o efeito causal apenas entre o subgrupo dos *compliers*, unidades cuja exposição ao tratamento muda na direção induzida pelo instrumento (Imbens 2010). Imagine um programa público de capacitação com vagas distribuídas por sorteio, mas adesão imperfeita: alguns sorteados não participam e alguns não sorteados conseguem acesso por outra via. Usar o resultado do sorteio como instrumento para a participação identifica o efeito entre as pessoas que participariam se sorteadas e não participariam se não sorteadas. A condição de monotonicidade exclui os “do contra”: ninguém deve deixar de participar por ter sido sorteado quando participaria sem o sorteio. O LATE não informa necessariamente o efeito entre todos os elegíveis nem o efeito de uma expansão universal do programa. Para decisões de política pública, saber a quem o efeito se refere é tão importante quanto conhecer sua magnitude.

Definir o estimando não garante que ele possa ser aprendido. Identificação é a demonstração de que, sob determinadas suposições, a quantidade causal pode ser expressa em termos da distribuição dos dados observados. Em outras palavras, um efeito identificado pode ser aprendido dos dados, enquanto um efeito não identificado não é recuperável nem com amostra infinita.

Assim, uma vez definido um estimando de interesse, a diferença entre um bom e um mau desenho de pesquisa é a credibilidade da identificação causal. Um bom desenho de pesquisa organiza a ponte entre estimando e dados de maneira crível. Em um experimento ideal, a atribuição aleatória faz com que grupos tratados e de controle sejam comparáveis em média, o que significa que o efeito causal médio é identificado. Em estudos observacionais, a comparabilidade precisa ser defendida de outras formas. A ausência de confundimento após condicionamento, tendências paralelas, continuidade em torno de um limiar e restrições de exclusão são suposições associadas a desenhos diferentes. Elas não são propriedades automáticas de regressões, pareamento, diferença-em-diferenças, regressão descontínua (RDD) ou variáveis instrumentais; são afirmações sobre o processo que gerou os dados e sobre o mundo social estudado.

Essa distinção também separa identificação de inferência estatística. A primeira pergunta se o desenho, junto às suposições, permite interpretar uma comparação observada como efeito causal. A segunda quantifica quanto a estimativa variaria diante da incerteza amostral ou de outras fontes explicitamente modeladas. Erros-padrão pequenos não corrigem confundimento; intervalos de confiança estreitos podem cercar uma quantidade enviesada. Inversamente, um desenho com argumento de identificação plausível pode produzir estimativas imprecisas. Credibilidade causal e precisão estatística são dimensões distintas e conjuntamente relevantes.

Em estudos observacionais, a identificação depende de medir e ajustar adequadamente as causas comuns do tratamento e do resultado. A chamada “revolução da credibilidade”, iniciada na economia e difundida por outras ciências sociais, valorizou essa atenção ao desenho porque especificações cada vez mais complexas não solucionavam a fragilidade das comparações subjacentes (Angrist e Pischke 2010).

Essa arquitetura também torna claro um limite da regressão múltipla tradicional. Até os anos 90, era comum tratar cada coeficiente como o efeito da respectiva variável e converter uma única equação em resposta à pergunta ampla sobre “as causas de Y ”. Mas a interpretação causal não é propriedade automática do coeficiente: para cada variável seria necessário definir o estimando e justificar, separadamente, por que os controles e a origem da variação identificam aquele efeito. Um mesmo ajuste raramente sustenta interpretações causais críveis de todos os coeficientes. Por isso, abordagens contemporâneas de inferência causal frequentemente concentram a análise no efeito de uma variável específica — ou de um pequeno

conjunto — por vez. As demais variáveis entram, em regra, como auxiliares à identificação ou à precisão desse estimando, não como efeitos adicionais prontos para interpretação. Hünermund e Louw recomendam omitir das tabelas os coeficientes dos controles ou marcá-los explicitamente como não causais, evitando induzir o leitor a interpretá-los como efeitos (Hünermund e Louw 2025).

DAGs ajudam a tornar esse argumento auditável. Se uma variável causa tanto o tratamento quanto o resultado, ela abre um caminho de confundimento que pode exigir bloqueio. Se, ao contrário, a variável é consequência comum de duas outras — um colisor —, condicioná-la pode criar associação onde antes não havia. Variáveis medidas após o tratamento podem representar mecanismos, efeitos intermediários ou novos colisores, e seu controle altera a pergunta respondida. Na linguagem dos modelos causais estruturais, intervir em X não equivale a apenas observar unidades com $X = x$. O grafo, porém, só é tão defensável quanto as relações causais nele postuladas.

Resultados potenciais tornam especialmente clara a necessidade do que a literatura chama de pressuposto SUTVA, de Stable Unit Treatment Value Assumption, ou seja, o resultado de uma unidade deve ser definido em relação a um tratamento suficientemente preciso, e não depender inadvertidamente do tratamento recebido por outras unidades. Já a representação gráfica facilita localizar caminhos pelos quais essas condições podem falhar.

De um ponto de vista lógico, primeiro deve vir a pergunta causal, depois, o estimando que a traduz. Em seguida, explicita-se a estrutura causal relevante, escolhe-se um desenho e declaram-se as suposições de identificação. Só então se selecionam estimador e procedimento de inferência compatíveis. Obviamente, na prática, teoria e evidência podem levar à revisão de etapas anteriores, em um processo de ida e vinda. Esse encadeamento pode ser pensado como uma disciplina argumentativa. Ao obrigar a pesquisadora a dizer o que pretende aprender e por que a comparação é informativa, impede que a interpretação causal seja acrescentada apenas depois que um coeficiente estatisticamente significativo apareceu. Como enfatizam Lundberg, Johnson e Stewart, estimandos claros conectam teoria, evidência e análise, mas não substituem a defesa da identificação (Lundberg, Johnson, e Stewart 2021).

3. Vantagens, limites e vieses conhecidos

A principal vantagem da formalização causal é a auditabilidade. Quando estimando, desenho e suposições são declarados, discordâncias deixam de se concentrar apenas na escolha de uma especificação e podem alcançar o argumento substantivo. Torna-se possível perguntar se o tratamento corresponde ao conceito teórico, se o grupo de comparação representa o contrafactual e se o efeito identificado responde à questão que motivou a pesquisa. O arcabouço formal também revela erros que, de outro modo, seria muito difícil descobrir.

Nesse sentido, uma pesquisadora interessada em realizar inferência causal deve se preocupar com as ameaças à sua estratégia de identificação. A principal delas é, possivelmente, o confundimento. Este ocorre quando causas do tratamento também influenciam o resultado. Municípios que adotam voluntariamente uma política, por exemplo, podem diferir de outros antes da adoção. Compará-los sem representar adequadamente esse processo mistura o efeito da política com diferenças prévias. O viés de seleção produz problema semelhante quando a entrada na amostra, a permanência no estudo ou a observação do resultado depende de tratamento e resultado. A solução típica pré-revolução causal, controlar para muitas covariáveis, não assegura que o problema tenha sido resolvido: algumas causas comuns podem não ter sido medidas, e a flexibilidade do ajuste pode apenas tornar menos transparente a dependência de suposições.

O controle também pode introduzir viés. Quando o estimando é o efeito total, variáveis afetadas pelo tratamento são, em geral, controles inadequados. Se a variável é um mediador, controlá-la bloqueia parte do caminho pelo qual o tratamento produz o resultado. Se é um colisor — um efeito comum do tratamento e de outra causa do resultado —, condicioná-la pode abrir um caminho não causal entre tratamento e resultado. Mediadores e colisores pós-tratamento são, portanto, *bad controls* para o efeito total, embora por razões distintas. A pergunta “por quais mecanismos?” é legítima, mas corresponde a outro estimando; analisar efeitos diretos exige métodos e suposições adicionais. DAGs são úteis porque distinguem visualmente confundidores, mediadores e colisores que uma lista indiferenciada de controles trataria como equivalentes.

Se a pesquisa consegue convencer de que seu desenho elimina as principais ameaças à identificação,

o desenho é dito crível e, se a amostra for suficiente para permitir que a inferência estatística seja bem feita, teremos um efeito causal crivelmente estimado. Isso, porém, não significa que chegamos ao Éden. Por exemplo, mesmo que os confundidores sejam adequadamente tratados, a comparação ainda pressupõe que o tratamento de uma unidade não altere o resultado de outra.

De fato, interferência e contaminação desafiam a ideia de unidades isoladas, presente no pressuposto de SUTVA. Campanhas, epidemias, redes sociais e políticas territoriais frequentemente produzem transbordamentos: o tratamento de uma unidade modifica o resultado de outra. Nesses casos, $Y_i(1)$ e $Y_i(0)$ são descrições incompletas, pois o resultado depende também da exposição alheia. A solução nem sempre é eliminar a interferência; frequentemente é redefinir tratamentos e estimandos para representar os padrões de exposição relevantes. Ignorá-la pode atenuar comparações ou fazê-las responder a uma combinação indeterminada de efeitos diretos e indiretos.

Endereçar SUTVA, contudo, não elimina todas as fontes de problemas. Erro de mensuração também pode mudar a pergunta causal. Indicadores administrativos podem registrar acesso ao programa, não tratamento efetivo; escalas de atitudes podem responder à própria intervenção; classificações territoriais podem ser alteradas pela política. O erro não se limita necessariamente a aumentar a incerteza: se for diferencial ou atingir tratamento, resultado e seleção de maneira relacionada, pode deslocar sistematicamente a estimativa. A validade de construto, portanto, integra a identificação e não é uma etapa meramente preliminar de limpeza de dados.

Mesmo os desenhos de pesquisa mais usados com sucesso para realizar inferência causal sob o paradigma da revolução da credibilidade enfrentam limitações conhecidas. Um experimento conduzido em condições ideais pode ter alta validade interna (identificar com credibilidade o efeito causal na amostra estudada), mas isso não garante validade externa para outras populações, épocas ou contextos. Nos experimentos naturais, o próprio desenho frequentemente restringe ainda mais a população à qual o estimando se refere. Assim, um RDD identifica o efeito causal próximo do ponto de corte; uma variável instrumental, sob as suposições usuais, identifica o efeito entre os compliers; e um desenho de diferença-em-diferenças costuma identificar o efeito sobre as unidades tratadas, não necessariamente o efeito médio em toda a população. Transportar esses efeitos para outras populações, épocas, subgrupos ou versões da intervenção requer informações e suposições adicionais.

Essa limitação de alcance é diferente de uma limitação de escopo. A linguagem de tratamentos é poderosa para estimar o efeito de intervenções específicas, mas nem toda explicação social assume naturalmente essa forma. Relações constitutivas, processos históricos dinâmicos e perguntas sobre as causas de eventos históricos específicos, como a Revolução Industrial, a ditadura militar brasileira ou a guerra entre a Rússia e a Ucrânia exigem mais do que a abordagem causal atual consegue entregar.

4. Exemplos de aplicação em ciências sociais

Dois estudos observacionais mostram como o desenho organiza a interpretação causal. Card e Krueger investigaram o efeito do aumento do salário mínimo de Nova Jersey sobre o emprego em restaurantes de *fast-food* (Card e Krueger 1994). Comparar apenas o emprego estadual antes e depois da mudança da política pública confundiria o efeito da política com choques temporais. Comparar apenas Nova Jersey e Pensilvânia depois da reforma confundiria a política com diferenças permanentes entre os estados. A diferença-em-diferenças combina os dois contrastes: pergunta quanto a mudança do emprego em Nova Jersey se afastou da mudança observada no estado vizinho, onde o salário mínimo não aumentou.

O estimando substantivo é o efeito da elevação do piso salarial sobre o emprego nos estabelecimentos tratados (cujo salário mínimo aumentou). O pressuposto-chave de identificação é a hipótese de tendências paralelas, ou seja, precisamos acreditar que, sem a reforma, a evolução temporal do emprego de Nova Jersey fosse similar à da Pensilvânia. Ao argumentar convincentemente que isso é plausível, os autores ajudaram a transformar o debate sobre salário mínimo entre economistas. Nos resultados principais reportados, os autores não encontraram a redução do emprego prevista pelo modelo microeconômico tradicional. O estudo tornou-se paradigmático por apresentar um desenho capaz de trazer evidências empíricas críveis sobre o efeito causal predito pela teoria dominante e contribuiu para que David Card, um dos autores do estudo, recebesse o Prêmio Nobel (Krueger faleceu antes do prêmio e certamente o dividiria com Card).

Em uma aplicação brasileira, Avelino, Biderman e Barone perguntam se eleger um prefeito aumenta posteriormente a votação de seu partido no município (Avelino, Biderman, e Barone 2012). Os autores conectam as eleições municipais de 2008 às votações para deputado federal e estadual em 2010 e exploram a descontinuidade produzida por vitórias apertadas. Partidos vencedores e derrotados por margens muito pequenas tendem a ser semelhantes em força eleitoral, mas apenas os vencedores passam a controlar a prefeitura. Assim, a posição imediatamente acima ou abaixo do limiar fornece uma comparação quase experimental para estimar o efeito de eleger o prefeito.

Usando uma amostra de eleições apertadas, o artigo reporta uma diferença estimada de 3,7 pontos percentuais na votação subsequente para deputado federal em comparação com o partido do prefeito que ficou em segundo lugar. Este é um dos primeiros artigos nacionais a aplicar RDD em eleições para estimar um efeito causal e trata de um tema substantivamente importante: o papel dos partidos nas eleições legislativas, em contraste com a interpretação então corrente de que os partidos brasileiros eram fracos na arena eleitoral.

Por óbvio, a lógica de identificação do RDD e seu alcance devem ser formulados localmente: partidos em disputas muito apertadas não representam automaticamente todos os municípios. Além disso, a literatura metodológica de RDD avançou desde que o artigo foi publicado. Hoje em dia, não se recomenda mais usar polinômios de quarto grau (era o estado da arte à época), e a escolha do que constitui eleição apertada é feita hoje por meio de algoritmos sofisticados, em vez de manualmente. O caso é, por isso, duplamente instrutivo: mostra a força de uma regra institucional para construir o contrafactual e recorda que a implementação de um desenho como esse requer também estar atento aos desenvolvimentos metodológicos.

5. Debates contemporâneos, escopo e Brasil

A revolução da credibilidade deslocou o padrão de justificação empírica. Em vez de confiar principalmente no ajuste de modelos e na inclusão de controles, os adeptos da moderna inferência causal passaram a valorizar experimentos, experimentos naturais e desenhos quase experimentais cuja fonte de variação pudesse ser explicada. Angrist e Pischke interpretaram essa mudança como resposta à baixa credibilidade da econometria aplicada (Angrist e Pischke 2010). Seu legado é a expectativa de que a credibilidade do desenho de pesquisa seja defendida antes da estimação.

Críticos temem que um efeito colateral importante seja a redução da ambição substantiva: diante dos incentivos de publicação, pesquisadores podem escolher estrategicamente perguntas menores com variação exógena evidente e transformar a robustez do desenho no principal critério de qualidade. Uma visão muito estreita do que é um desenho de pesquisa rigoroso certamente limitaria o tipo de pergunta de pesquisa que poderia ser feita. No limite, excluiríamos do rol de boa ciência o que não pode ser conduzido por experimentos, ou pelo menos traduzido em sua linguagem e julgado por esse “padrão ouro”.

Imbens reconhece esse risco em *Better LATE Than Nothing*, mas defende que não temos nada a ganhar ao abandonar o uso de desenhos críveis quando são possíveis para perguntas de pesquisa de interesse. Em sua formulação, um efeito local crível é preferível a um efeito geral pouco crível (Imbens 2010). Esse estreitamento não é defeito necessário da revolução; é resposta evitável da comunidade científica à elevação da barra. Periódicos, pareceristas e pesquisadores podem exigir simultaneamente relevância substantiva e respostas críveis. Tampouco está demonstrado que a agenda tenha se tornado menos relevante ou ambiciosa; demonstrá-lo exigiria medir relevância e ambição antes e depois da mudança metodológica, o que o debate citado não faz. Elevar a barra é desejável. O desafio é não reduzir a pergunta para alcançá-la, mas mobilizar criatividade para encontrar variações informativas, combinar desenhos e construir novas bases de dados.

Torreblanca e colaboradores permitem dimensionar a difusão dessa expectativa na Ciência Política internacional (Torreblanca et al. 2026). O estudo classificou 91.632 artigos publicados entre 2003 e 2023 em 156 periódicos internacionais. Os autores encontram crescimento de pesquisas baseadas em desenho e associação positiva com citações. A transformação, contudo, é parcial e desigual: concentra-se em periódicos de maior prestígio e em instituições mais bem posicionadas nas classificações, é impulsionada sobretudo por experimentos de survey e convive com o uso ainda raro de testes de placebo e cálculos de poder estatístico. Em suma, os resultados documentam difusão crescente, mas desigual da atenção a estimandos, desenhos e questões de inferência estatística.

Em estudo similar, mas para o caso brasileiro, Galdino e Martins da Silva analisaram o texto integral

de 4.144 artigos elegíveis publicados entre 2005 e 2025 em nove periódicos brasileiros indexados no SciELO (Galdino e Martins da Silva 2026). Dos 1.999 artigos quantitativos, 1.994 têm informação disponível sobre inferência estatística; apenas 743 deles, ou 37%, quantificam formalmente a incerteza. Em outras palavras, 63% não calculam p-valor, intervalo de confiança ou outra medida similar de inferência estatística. Apenas apresentam números ou estatísticas descritivas que passam longe do debate apresentado aqui neste verbete. Entre os 1.999 quantitativos, 1.944, ou 97,2%, possuem pretensão explicativa, isto é, querem estabelecer relações de causa e efeito. Destes, apenas 59, ou 3,0%, mencionam uma estratégia explícita de identificação causal; 1.885, ou 97,0%, não o fazem. O descompasso entre ambição e método é evidente. Estamos longe da fronteira metodológica nas publicações nacionais.

Estamos, claro, falando de métodos quantitativos causais. *Process tracing*, análise histórico-comparativa, QCA e outras abordagens configuracionais também formulam perguntas causais, frequentemente concentradas em mecanismos, sequências, condições necessárias ou combinações suficientes e estão presentes nos periódicos brasileiros. Por limitação de espaço, não abordamos aqui essas outras tradições causais.

Essa delimitação preserva uma distinção importante. Causas podem ser tratadas como intervenções, mas também como condições dentro de configurações, processos que conectam eventos ou estruturas que constituem atores e possibilidades. Explicar o efeito de uma mudança não é o mesmo que reconstruir seu mecanismo, interpretar seu significado ou mostrar como uma categoria social foi constituída. A clareza causal exige reconhecer tanto o que o desenho identifica quanto o que permanece fora dele.

A virada moderna, portanto, não encerrou a pluralidade das explicações sociais. Ela elevou o padrão mínimo para uma classe importante de alegações: quando uma pesquisa afirma que mudar X alteraria Y , precisa definir a quantidade causal, justificar a comparação que representa o contrafactual e separar identificação de incerteza estatística. Métodos podem mudar e diagnósticos podem se tornar mais exigentes. A exigência permanece: dizer qual efeito está em jogo e por que os dados permitem aprendê-lo.

6. Referências e leituras adicionais

Textos fundadores: Hill organiza o julgamento causal observacional; Rubin coloca os resultados potenciais no centro de estudos experimentais e observacionais e reconstrói em entrevista a genealogia que remonta a Neyman; Pearl dá aos grafos causais sua formalização moderna (Hill 1965; D. B. Rubin 1974; D. Rubin 2022; Pearl 2009).

Desenho e estimandos: Angrist e Pischke sintetizam a revolução da credibilidade; Imbens defende o ganho de validade interna; Lundberg, Johnson e Stewart mostram a função teórica do estimando (Angrist e Pischke 2010; Imbens 2010; Lundberg, Johnson, e Stewart 2021).

Aplicações observacionais: Card e Krueger exemplificam diferença-em-diferenças; Avelino, Biderman e Barone aplicam RDD a eleições brasileiras (Card e Krueger 1994; Avelino, Biderman, e Barone 2012).

Controles, fronteira e Brasil: Hünernmund e Louw discutem a interpretação dos coeficientes de controle; Torreblanca e colaboradores documentam a difusão internacional; Galdino e Martins da Silva analisam os periódicos brasileiros (Hünernmund e Louw 2025; Torreblanca et al. 2026; Galdino e Martins da Silva 2026).

Angrist, Joshua D., e Jörn-Steffen Pischke. 2010. “The Credibility Revolution in Empirical Economics: How Better Research Design Is Taking the Con out of Econometrics”. *Journal of Economic Perspectives* 24 (2): 3–30.

Avelino, George, Ciro Biderman, e Leonardo S. Barone. 2012. “Articulações Intrapartidárias e Desempenho Eleitoral no Brasil”. *Dados* 55 (4): 987–1013. <https://doi.org/10.1590/S0011-52582012000400005>.

Card, David, e Alan B. Krueger. 1994. “Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania”. *American Economic Review* 84 (4): 772–93.

Galdino, Manoel, e Rodrigo Martins da Silva. 2026. “Depois do calcanhar metodológico: inferência e identificação causal na Ciência Política brasileira”. Em *Paper apresentado no 15º Encontro da Associação Brasileira de Ciência Política*, 4 de agosto de 2026.

Hill, Austin Bradford. 1965. “The Environment and Disease: Association or Causation?” *Proceedings of the*

- Royal Society of Medicine* 58 (5): 295–300.
- Hünermund, Paul, e Beyers Louw. 2025. “On the Nuisance of Control Variables in Causal Regression Analysis”. *Organizational Research Methods* 28 (1): 138–51. <https://doi.org/10.1177/10944281231219274>.
- Imbens, Guido W. 2010. “Better LATE Than Nothing: Some Comments on Deaton (2009) and Heckman and Urzua (2009)”. *Journal of Economic Literature* 48 (2): 399–423. <https://doi.org/10.1257/jel.48.2.399>.
- Lundberg, Ian, Rebecca Johnson, e Brandon M. Stewart. 2021. “What Is Your Estimand? Defining the Target Quantity Connects Statistical Evidence to Theory”. *American Sociological Review* 86 (3): 532–65. <https://doi.org/10.1177/00031224211004187>.
- Pearl, Judea. 2009. *Causality: Models, Reasoning, and Inference*. 2^o ed. Cambridge: Cambridge University Press.
- Rubin, Don. 2022. “Interview with Don Rubin”. *Observational Studies* 8 (2): 77–94. <https://doi.org/10.1353/obs.2022.0009>.
- Rubin, Donald B. 1974. “Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies”. *Journal of Educational Psychology* 66 (5): 688–701.
- Torreblanca, Carolina, William Dinneen, Guy Grossman, e Yiqing Xu. 2026. “The Credibility Revolution in Political Science”. <https://doi.org/10.48550/arXiv.2601.11542>.

7. Ver também

- Desenho de pesquisa;
- Explicação;
- Mecanismos causais;
- Experimentos;
- *Process tracing*;
- Correlação;
- Validade interna e externa.

8. Como citar este verbete